

FORD

Sprint de Inteligência Artificial & Machine Learning

Segmentação e Classificação de Clientes

Estratégia de Retenção na Rede Oficial de Serviços

Arthur Bobadilla Franchi - RM555056

Luan Orlandelli Ramos - RM554747

Jorge Luiz - RM554418

1. Contexto de Negócio e Objetivo

Desafio Central

A Ford enfrenta um problema de assimetria de informação no ponto de venda: no momento da compra do veículo, a concessionária desconhece qual será o comportamento futuro do cliente em relação a manutenção na rede oficial. Isso impede ações de retenção proativas e personalizadas, resultando em perda de receita recorrente e de oportunidades de fidelização.


Por que a retenção na rede oficial importa?

O veículo representa apenas o ponto de entrada do relacionamento. O ciclo de vida completo, revisões periódicas, troca de peças e manutenções preventivas é a principal fonte de receita recorrente da rede autorizada e o canal mais eficaz para estimular a recompra futura de um Ford.

- Perda direta de receita: serviços de manutenção possuem margem superior à venda do veículo.
- Perda de controle sobre a experiência da marca: clientes em oficinas externas ficam fora do ecossistema Ford.
- Redução da probabilidade de recompra: clientes que abandonam a rede raramente voltam a comprar Ford.

Abordagem Analítica: Solução em Duas Etapas

Para resolver esse problema, o projeto foi estruturado em dois estágios complementares, garantindo que nenhuma informação futura contamine o modelo preditivo (princípio anti-data leakage):



2. Bases de Dados e Qualidade

Estrutura dos Dados

Atributo	Base 1 - Histórico	Base 2 - Compra
Registros	500.000	500.000
Variáveis totais	37	24
Variáveis do momento da compra	23	23
Variáveis comportamentais pós-venda	12	N/A (proibido)
Taxa de nulos	0,4%	1,2%
Uso no projeto	Segmentação (Etapa 1)	Classificação (Etapa 2)

Decisões de Pré-processamento


Problema	Decisao	Justificativa Tecnica
Valores nulos (<2,5% por coluna)	Imputação por mediana	Robusta a outliers; taxa baixa nao distorce distribuição
330 registros: compra_a_vista=0 e prazo=0	Corrigido para compra_a_vista=1	Inconsistência lógica: sem prazo de financiamento = pagamento a vista
Outliers em renda, distancia e gasto	Winsorizacao 1%-99%	Preserva distribuição real, elimina extremos esguios
Variáveis categóricas (5 colunas)	One-Hot Encoding	Compatibilidade com algoritmos baseados em distância euclidiana
Escalas heterogêneas	StandardScaler	K-Means e Logistic Regression são sensíveis a magnitude das variáveis

3. Segmentação Comportamental - Etapa 1

Metodologia: K-Means Clustering

O algoritmo K-Means foi aplicado sobre as 12 variáveis comportamentais pós-venda da Base 1, que representam o comportamento real de cada cliente ao longo de 24 meses após a compra. A escolha exclusiva de variáveis comportamentais garante que os clusters capturem como o cliente se comporta, não apenas quem ele é no cadastro.


Definição do Número de Clusters: k = 4





A escolha de k=4 combina rigor técnico e alinhamento com o negócio:

- Técnico: ponto de inflexão evidente no Elbow; diferença de Silhouette para k=5/6 inferior a 0,01.
- Negócio: corresponde exatamente às 4 hipóteses de perfil levantadas pelo gerente de atendimento.
- Operacional: 4 segmentos são gerenciados para a equipe da concessionária implementar ações distintas.

Distribuição dos Segmentos



3. Segmentação - Perfil Comportamental



4. Personas de Negócio - Os 4 Perfis Ford

FIEL | 150.734 clientes - 30,1%

3,95 Revisões 24m	93,1% Share Rede	R\$ 4.266 Gasto	9,4/10 Satisfação	2,2% Churn
Cliente de alto valor, comprometido com a rede oficial independentemente de preço ou promoções. Realiza quase todas as revisões na rede, apresenta alta satisfação e raramente realiza churn.				
Estratégia de Retenção: • Programa de fidelidade premium (cartão Ford Fiel, benefícios exclusivos) • Consultor dedicado com acesso ao histórico completo • Pipeline de recompra: comunicação proativa sobre novos modelos • Monitoramento de NPS como radar de alerta precoce				

ECONÔMICO | 126.864 clientes - 25,4%

2,73 Revisões 24m	57,4% Share Rede	R\$ 1.429 Gasto	7,1/10 Satisfação	7,1% Churn
Cliente presente, mas transacional. Alterna entre a rede oficial e alternativas externas conforme o custo. Alta sensibilidade a desconto (0,86). Retém quando o preço é competitivo.				
Estratégia de Retenção: • Plano de manutenção com desconto prefixado ofertado no ato da compra • Alertas personalizados de campanhas antes das datas de revisão • Gamificação de benefícios: cada revisão acumula vantagem crescente • Monitoramento de pricing de concorrentes externos na região				

ESQUECIDO | 118.754 clientes - 23,8%

17,4% 1a Revisão	96% Perdeu Prazo	26,2% Share Rede	3,9/10 Satisfação	25,3% Churn
Perfil mais caótico. Apenas 17% realizou a 1ª revisão na rede; 96% perdeu o prazo. Quando retorna tarde, em 46% dos casos o frustra. Alto risco de dano à imagem da marca.				
Estratégia de Retenção: • Comunicação proativa por SMS/WhatsApp/e-mail 30 e 15 dias antes do prazo • Flexibilização de cobertura para revisões com leve atraso • Agendamento simplificado: link único, sem burocracia • Oferta de app de lembretes no ato da compra como benefício gratuito				

ABANDONO | 103.648 clientes - 20,7%**94,5%**

1a Revisão

17,4%

Share Rede

R\$ 213

Gasto

4,8/10

Satisfação

27,5%

Churn

Realiza a 1a revisão em 94% dos casos (pressão de garantia), mas abandona em seguida. Gasto acumulado mínimo (R\$213). Traz óleo externo em 63% das visitas. Churn de 27,5%.

Estratégia de Retenção:

- Experiência diferenciada na 1a revisão: única janela confiável de presença
- Oferta de captura na 1a revisão: desconto condicionado ao agendamento da 2a
- Diagnóstico gratuito na 2a visita para reduzir barreira de custo percebido
- Canal digital simplificado de agendamento: conveniência como diferencial

5. Classificação Preditiva - Etapa 2

Objetivo e Metodologia


Após definir os segmentos na Etapa 1, os rótulos dos clusters foram transformados em variáveis-alvo supervisionada. Um modelo de classificação foi treinado utilizando exclusivamente as variáveis disponíveis no momento da compra (Base 2), simulando o cenário real de operação da concessionária.

Comparação de Algoritmos

Modelo	Acurácia	F1 Macro	F1 Weighted	Decisao
Logistic Regression	79,0%	0,766	0,786	Eleito
Random Forest	78,8%	0,768	0,785	Comparativo
Decision Tree	74,3%	0,741	0,742	Baseline


A Logistic Regression foi eleita por: (1) melhor acurácia geral; (2) interpretação nativa dos coeficientes por classe; (3) inferência em tempo real sem custo computacional relevante ideal para integração no CRM da concessionária.

Métricas Detalhadas por Classe



Segmento	Precisão	Recall	F1-Score	Interpretação
Fiel	0,97	0,98	0,97	Perfil mais discriminável - acerto quase perfeito
Econômico	0,80	0,86	0,83	Boa precisão; alguma confusão com Esquecido
Esquecido	0,69	0,72	0,71	Erros predominantemente trocados com Abandono
Abandono	0,61	0,52	0,56	Classe mais difícil - perfil de compra similar ao Esquecido

5. Classificação - Matriz de Confusão e Drivers



Análise da Matriz de Confusão

A diagonal principal reflete as previsões corretas. A confusão entre Abandono e Esquecido é estrutural: ambos compartilham baixo planejamento de manutenção no ato da compra, com a diferença sendo fundamentalmente comportamental. Do ponto de vista de negócio, esse erro é aceitável: classificar um Esquecido como Abandono (ou vice-versa) ainda aciona o protocolo correto intervenção de alto risco.

Top 5 Drivers Preditivos

Feature	Interpretação de Negócio
organizacao_proxy (0,25)	Comportamento organizado no ato da compra prediz fortemente o perfil Fiel.
sensibilidade_preco_inicial (0,25)	Alta sensibilidade inicial discrimina Econômico e Abandono.
tempo_decisao_dias (0,08)	Decisão rápida correlaciona com Abandono; decisão lenta com Econômico.
distancia_concessionaria_km (0,08)	Maior distância eleva probabilidade de evasão futura.
score_credito (0,05)	Score mais alto associado ao perfil Fiel.

6. Leitura Executiva e Recomendações

Quais segmentos representam maior risco de evasão?

Segmento	Churn	% Base	Receita em Risco	Prioridade
Abandono	27,5%	20,7%	R\$ 213/cliente (24m)	ALTA
Esquecido	25,3%	23,8%	R\$ 315/cliente (24m)	ALTA
Econômico	7,1%	25,4%	R\$ 1.429/cliente (24m)	MÉDIA
Fiel	2,2%	30,1%	R\$ 4.266/cliente (24m)	BAIXA

Impacto Esperado por 100.000 Novos Clientes

Segmento	N Estimado	Acao Ativada no Dia da Compra
Fiel (~30k)	~30.000	Programa premium + pipeline de recompra ativado
Econômico (~25k)	~25.000	Oferta de plano de manutenção com desconto no ato da compra
Esquecido (~24k)	~24.000	Cadastro em alertas automáticos + agendamento assistido
Abandono (~21k)	~21.000	Protocolo de captura na 1a revisão + oferta de retorno imediato

Como a solução opera no dia a dia da concessionária?

ANTES	DEPOIS
Todos os clientes recebem a mesma abordagem pós-venda. Nenhuma diferenciação.	Modelo classifica o cliente no ato da compra e aciona um protocolo personalizado.

7. Conclusão

O que foi construído

Este Sprint entregou uma solução analítica completa e operacionalizável que transforma a assimetria de informação no momento da compra em vantagem competitiva para a rede Ford. O pipeline cobre desde a descoberta dos perfis reais de comportamento até a previsão desses perfis para novos clientes antes de qualquer sinal pós-venda.

Etapa	Método	Resultado Principal
EDA e Preparação	Análise estatística	0,4% nulos; 37 variáveis classificadas; pipeline de tratamento documentado
Segmentação (Etapa 2)	K-Means (k=4)	Silhouette 0,32; >91% concordancia com ground truth; 4 personas nomeadas
Classificação (Etapa 3)	Logistic Regression	79% acurácia; F1 macro 0,77; Fiel com F1=0,97; zero data leakage